




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

MCM2025-C 真题解析

汇报人：单若水 焦悦 李雨桐 孙锦涵



目 录



01-题目介绍

02-思路分析

03-论文介绍

04-总结与建议

01

2025年C题介绍



2025年C题介绍

2025 MCM

Problem C: Models for Olympic Medal Tables



C题（数据洞察）

需处理**大规模数据集**并**应用机器学习算法**

数据科学、统计学类



奥运会奖牌榜模型

美赛C题是**数据驱动**型建模问题。要求基于提供的大规模历史数据集，构建**预测模型**和**解释性模型**。本题是一个关于**预测奥运会奖牌榜**的问题。核心任务是利用提供的**历届奥运会数据**，构建模型来**分析和预测**各国在下一届奥运会的表现。

2025年C题介绍

□ 任务1：建立奖牌预测模型

至少包括金牌数和总奖牌数

- **核心任务：** 为每个国家建立奖牌数预测模型。（不确定性/精确度估计、性能度量。）
- 预测2028年洛杉矶奥运会**奖牌榜**，提供**预测区间**。分析哪些国家会**进步/退步**。
- 预测有多少无奖牌国家将在下届奥运会获得**首枚奖牌**，并评估其**可能性**。
- 分析奥运**项目设置**（数量与类型）与各国奖牌数的关系。识别对不同国家**最重要的**运动项目。探究**主办国项目设置**对结果的影响。

□ 任务2：分析“伟大教练”效应

例：郎平(美国、中国)，贝拉·卡洛伊(罗马尼亚、美国)

- **核心任务：** 分析顶尖教练更换执教国家后，是否对该国的**奖牌产出**有显著影响。
- **关键问题：** 从数据中寻找教练影响的**证据**；量化教练对奖牌的**贡献程度**；为3个国家**推荐**值得聘请顶级教练的项目，并估算效果。

□ 任务3：提供独到见解

- **核心任务：** 从模型提取奥运奖牌数的**独到见解**。说明其为各国奥委会提供的参考。

提供数据

□ 数据文件：5个.csv文件

- _data_dictionary.csv：数据**字典**文件，解释其他数据文件中各字段的含义并提供示例
- _summerOly_athletes.csv：历代所有夏季奥运会**运动员个人参赛记录**，包括参赛年份、项目、国家、获得奖牌情况。
- _summerOly_medal_counts.csv：历届奥运会**各国金、银、铜牌及总奖牌数**。
- _summerOly_hosts.csv：所有已举办和已确定的未来夏季奥运会**的主办国**。
- _summerOly_programs.csv：历届奥运会不同运动**大项**和分项设置的**小项**数量。

□ 数据处理**注意事项**：

- 数据集中的**国家名称和标识**可能随时间变化，需要处理历史上的国家变迁等情况。
- 可能存在**记录异常**，需要数据清洗和预处理。
- 某些**团队**项目的表示方式需要特殊处理。

Decisions and assumptions about how to handle the data are an important part of the modeling process.

02

解题思路分析



整体解题思路

1. 数据预处理

2. 2028年奖牌预测

3. 首次夺牌预测

4. 项目重要性分析

5. 伟大教练效应

6. 提供独到见解

任务一

任务二

任务三

2025 MCM PROBLEM C

SOLUTION OUTLINE



1.数据预处理--存在问题

Name	Team
Daniel Escolar	Spain
Jos Muiz	Spain-2

- ❑ **1.国家名称与政治实体变化：** 历史数据中，国家名称、边界、政治实体可能发生变化（如苏联、东德、西德等）。
- ❑ **2.运动员团队表示不一致：** 队伍名称可能包含“国家-编号”（如Germany-1表示 2000 年奥运会德国两支沙滩排球队中的第一支），而不是纯国家名。
- ❑ **3. 缺失值与记录异常：** 早期奥运会记录不完整，某些运动员或奖牌记录可能缺失，数据中可能存在重复记录或错误编码。
- ❑ **4. 奥运会项目与分类变化：** 奥运项目数量、类型、分类随时间变化。某些项目被取消或新增。
- ❑ **5. 数据规模与计算效率：** 运动员数据量庞大，运动项目多，包含多个维度。

1.数据预处理--解决方案

处理环节	O	O	F	M	H	S
数据整合	自然连接、聚合	分组、分类	多源数据整合	统一国名, 建综合表	统一国名, 拆分特征	整合基础数据
缺失值处理	插值、删除	未说明	数据验证、清洗	未说明	后向填充	假设数据合规
特征工程	权重分配(50-30-20)	奖牌百分比转换	滞后特征、主办国特征	优势项目定义	多层次特征+交互项	国家分类, 虚拟变量
标准化	未说明	未说明	Z-score标准化	Z-score标准化	标准化处理	未说明
维度缩减	PCA降维	项目级别分析	PCA降维	特征选择	剔除共线性特征	国家分类分组

2.2028年奖牌预测



任务目标:

预测2028年洛杉矶奥运会**奖牌榜**，提供**预测区间**。分析哪些国家会**进步/退步**。



任务分析:

预测奖牌本质上是一个**多特征、强非线性预测问题**。

数据量不够深度模型用，关系结构又不够简单线性回归能解决。



解题思路:

1. 特征工程：构造有用特征

为什么、如何构造有效特征？

2. 建模：选择合适的预测模型

如何选择合适模型？

3. 模型分析：得到置信区间

如Bootstrap

4. 分析输出，数据 → 解释性分析

2.2028年奖牌预测--特征工程

为什么要构造特征?

原始数据本身不能预测未来，其信息量远远不够。

预测奖牌本质上预测的是：

- 一个国家的体育体系强度
- 项目配置对该国的偏向程度
- 主办国效应
- 趋势（增强/衰退）
- 每个sport的未来结构变化

这些因素，须**显式或隐式地建模**。

因此，特征工程是模型成功的关键。

如何构造有效特征?

例1. 构建代表体育实力的基础特征。

$$S = N_G \omega_G + N_S \omega_S + N_B \omega_B$$
$$\omega_G = 3, \quad \omega_S = 2, \quad \omega_B = 1.$$

例2. 简化 sport 维度。

PCA：把多个运动项目降为几个主成分。

例3. 主办国效应。

$$\alpha_c = \frac{\text{Gold}_c^{\text{host}} - \text{Gold}_c^{\text{avg}}}{\text{Gold}_c^{\text{avg}}}$$

2.2028年奖牌预测—模型选择

神经网络?

可能问题：数据量太小（只有几十届，约200国家），会过拟合，调参困难

线性回归?

问题：奖牌与特征关系明显非线性

随机森林?

可能问题：对稀疏特征难处理，无法很好处理趋势特征。

XGBoost?

优势：能处理小数据，能表达复杂非线性结构，有天然的特征重要性

3.首次夺牌预测



任务特征:

这是一个“事件是否发生”的问题，并且这个事件只能发生一次。



可能误区:

- 1: 用分类模型，忽略了时间信息。
- 2: 用简单规则判断，过于粗糙，没有数学结构。
- 3: 特征不够。
- 4: 忽略区域差异影响。
- 5: 忽略“不确定性”（概率很低，需用区间体现）。



方法举例:

Cox比例风险模型:

用于分析生存数据，即研究**某个事件发生的时间与一个或多个预测变量**之间的关系。

不直接预测生存时间，通过风险函数来刻画不同特征的个体在某一时刻发生事件的“**风险率**”的相对大小。

4.项目重要性分析

哪些体育项目最能影响一个国家的奖牌数量？

——项目重要性

思路示例：

1. **Spearman 相关分析**

奖牌数量**分布偏态严重，非线性关系，明显等级关系。**适用Spearman。

2. **SHAP**

SHAP用于解释任何一个机器学习模型的**单个预测结果**，给出每个特征对这个特定预测值的贡献值。适用于此题。

不同国家在不同项目的优势结构是否决定奖牌分布？

——国家-项目匹配

思路示例：

1. 如何匹配？

构建国家的**优势项目向量**...

2. 如何分析？

聚类，项目得分**贡献分解**...

主办国的项目设置是否会
影响其奖牌数？

——主办国效应

思路示例：

1. 主办国在其优势项目会有更强表现——如何量化？

构建系数...

2. **时间序列**视角看项目数量变化趋势：趋势增加，项目前景好；反之，项目前景差。

3. 主办国如何最大化奖牌？

优先提高其强项，推广国家传统优势项目，减少竞争激烈的项目.....

5.伟大教练效应—问题分析

问题分析：

不是预测问题，而是**因果推断**。

可以考虑以下问题：

教练到来之前 vs 教练到来之后，全国表现是否变化？

如果教练没有来，会发生什么？

如何排除国家投资更多、政策改变、项目改变...带来的干扰？

为什么不能简单进行前后对比？

奖牌表现本身就随时间变化，项目数量会随着奥运调整，国家资金投入也可能随时间增加...

——**必须隔离教练的影响**

思路：

构建对照组，提取教练带来的真实增益。——**DID**

5.伟大教练效应—解答思路

从数据中寻找教练影响的证据

从表现变化中**逆向推断**可能存在的教练影响。

需识别：

某国某项目，**绩效**曲线是否出现了**突变或跳升**？这种“跳升”是否不能用一般波动解释？

方法示例：

异常检测算法，跨国对比

量化教练对奖牌的贡献

某国因为聘请教练而提升了多少？

如果没有教练会怎样？

思路示例：**DID**

1. 找到教练介入点。
2. 构建**对照**：
 - 处理组：该国家该项目
 - 对照组：其他国家同项目
3. **比较前后变化的差异**。

推荐最值得投资顶级教练的项目，并估计效果

思路示例：

1.构建**项目教练弹性**。
弹性越大，教练投入的回报越高；弹性越低，教练作用有限。

2.计算国家**最具提升空间的项目**。

寻找“弱项 + 高回报”的项目，适合聘请顶级教练。

3.估算聘请后的奖牌增益

6.提供独到见解



如何理解？

不是通过模型算出了什么，
而是透过模型看到的**结构性逻辑、启发性见解**。

如：

为什么会这样？

未来可能怎样？

结构性的规律是什么？

对奥运政策、体育发展有什么启发？



如何提出？

见解是从前面任务的**模型结果**中抽象出来的。

展示了：

你对问题的理解深不深。

能否提出别人没想到的规律性观点。

是否有能力把数学模型转化为现实世界的战略价值。



方法举例：

以奖牌榜预测为例：

模型显示：

哪些特征最影响奖牌，哪些项目决定了强国地位，哪些国家处于上升趋势...

见解总结：

奖牌结构具有显著路径依赖。不同国家依赖不同项目结构。

03

各等次论文分析



论文架构

1. Introduction
2. Assumptions and Justification
3. Data process
4. Tasks
 - a. Task1:Medal table prediction model
 - b. Task2:Great Coach Effect
 - c. Task3:Original Insights
5. Sensitivity Analysis
6. Model Evalution and Further Discussion

Contents

31 Introduction.....	3
1.1 Problem Background	3
1.2 Restatement of the Problem	3
1.3 Literature Review.....	3
1.4 Our Work.....	4
2 Assumptions and Justifications.....	4
3 Notations	5
4 Data process.....	5
4.1 Outlier handling	5
4.2 Data integration.....	6
5 Task1 Medal table prediction model	7
5.1 Problem 1 negative binomial distribution model.....	7
5.2 Problem 2 Geometric distribution model.....	10
5.3 Problem 3 N-B Regression for Project-Impact Analysis Model.....	12
6 Task 2 Great Coach Effect.....	14
6.1 Problem analysis	14
6.2 Comprehensive Model of Elastic Network and Polynomial Regression	14
7 Task 3 Original insights.....	19
7.1 Impact of GDP on the number of medals	19
7.2 Impact of region on the number of medals	21
7.3 Suggestion for country Olympic committees.....	21
8 Sensitivity Analysis.....	22
8.1 Sensitivity of predicting the number of athletes.....	22
8.2 Sensity of Golds and Medals' Prediction	22
9 Model Evaluation and Further Discussion.....	23
9.1 Strengths	23
9.2 Weaknesses	24
9.3 Further Discussion	24
10 Conclusion.....	24
References	24

数据预处理



异常值处理

- 移除国家名称后冗余字符串
- 统一国家名称
(e.g. 苏联->俄罗斯)



数据集成

- 合并奖牌、运动员、主办国数据
- 构建summary.csv



特征构建

- 引入虚拟变量主办国
- 定义优势项目 (连续三年金牌概率 > 30%)
- 引入新特征: 项目参与数与新项目数



任务一

负二项回归 奖牌数量预测

奥运奖牌数据呈现典型的过度离散特征。采用负二项回归能更准确地刻画奖牌分布的异质性，其预测区间也因考虑了过度离散而更为合理。

$$\ln G_{pre} = \lambda_1 y + \lambda_2 h + \lambda_3 e_t + \lambda_4 d + \lambda_5 G_{his} + \lambda_6 A + \xi$$




Figure 4: United States's medals over time with fitted curve

几何分布 首次获奖国家预测

将一个国家每参加一届奥运会视为一次伯努利试验。通过统计各国在各项目的累计参赛运动员数，计算其不同项目上的平均获奖概率、首次获奖总概率和首次获奖国家数量的期望。

$$P = 1 - \prod_{i=1}^k (1 - P_i), \quad E[X] = \sum_{i=1}^n p_i = 24$$




Figure 5: Possibility of earning medals and gold medals

模型优化 优势项目分析

- 通过计算协方差/相关系数，发现优秀运动员数量和优势项目与奖牌数量存在显著相关性。
- 在初始负二项回归模型中加入这两个变量，再次拟合。




Figure 6: Correlation heatmap for United States

任务二：伟大教练效应



模型构建：弹性网络+多项式回归

- 典型案例：刘国梁执教中国乒乓球队。
- 弹性网络回归：解决教练数据样本量小、变量间存在多重共线性的问题。
- 二次多项式项：捕捉教练与团队磨合过程中产生的非线性动态特征。
- 因变量：标准化后的奖牌得分（金=3，银=2，铜=1）。
- 自变量：获奖运动员比例、标准化年份、是否执教的虚拟变量及其交互项。







量化+迁移

- 分别拟合了刘国梁执教时期与执教前期的数据，生成两条不同的预测曲线，计算其差值。
- 根据目标国家（德国、日本、瑞典）的运动员规模进行比例缩放，预测这些国家若引入同级教练可能带来的提升。



任务三：经济与区域因素分析



- GDP相关性：热图显示GDP与奖牌数显著正相关
- 区域分布：北美、欧洲、亚洲奖牌数领先
- 建议：增设适合新兴国家的项目；建立国际教练与数据共享平台；优化奥委会资源分配策略



论文架构

- 1. Introduction
- 2. Assumptions and Justification
- 3. Data Processing
- 4. Problems
 - a. Problem1: A Prediction for Medal Standings
 - b. Problem2: Great Coach Effect
- 5. Model Summary

Contents	
1	Introduction 2
1.1	Background 2
1.2	Restatement of Problems 2
1.3	Literature Review 3
2	Our Work 3
3	Assumptions and Justification 4
4	Notations 4
5	Data Processing 5
5.1	Data Cleaning 5
5.2	Feature Engineering 5
5.2.1	Host Country Features 6
5.2.2	Participation Features 6
5.2.3	Historical Performance Features 7
5.2.4	Event Features 8
6	Problem1: A Predictive Model for Olympic Medal Standings 8
6.1	Feature Preprocessing 8
6.2	Model Establishment:Multi-target XGBoost Framework 10
6.3	Model Training and Evaluation 11
6.4	2028 Olympic Medal Projections with Strategic Analysis 12
6.5	Medal Breakthrough Probability Prediction Model 13
6.6	Host Country And New Event Correlation 14
7	Problem2: Great Coach Effect Analysis 16
7.1	Identification and Quantification of Great Coach Effect 16
7.2	Causal Inference of Coaching Effects 18
7.3	Optimizing Olympic Investments Through Coach Effect Analysis 19
8	Model Summary 19
8.1	Strength 19
8.2	Weakness 20
8.3	Sensitive Analysis 20
8.3.1	Parameter Sensitivity 20
8.3.2	Feature Importance Analysis 20
	Reference 22

Dataset




Figure 1: The flowchart of our work



Highlight 1 – 多种先进模型组合

PCA+LSTM+XGBoost+Bootstrap = 组合进行预测、分类、变点识别和因果推断





方法	在论文中的作用	原理
XGBoost	预测金/银/铜奖牌数（多目标回归）	通过梯度提升叠加树模型，自动拟合非线性与特征交互
SVM	预测国家是否会“零突破”（二分类）	在高维空间构造最大间隔超平面，实现最优分类
CUSUM	检测 medal 表现的突变年份	累积偏差到一定阈值，用于识别序列的结构变化点
DID	估计换教练的因果效应	比较实验组与对照组在前后时期的差异变化
Bootstrap	为预测构建置信区间	重复有放回抽样，估计预测分布和不确定性
TSCV	检验预测模型在时间序列上的泛化能力	按时间滚动切分训练/验证集，避免未来信息泄露



Highlight 2 – 评估方法科学

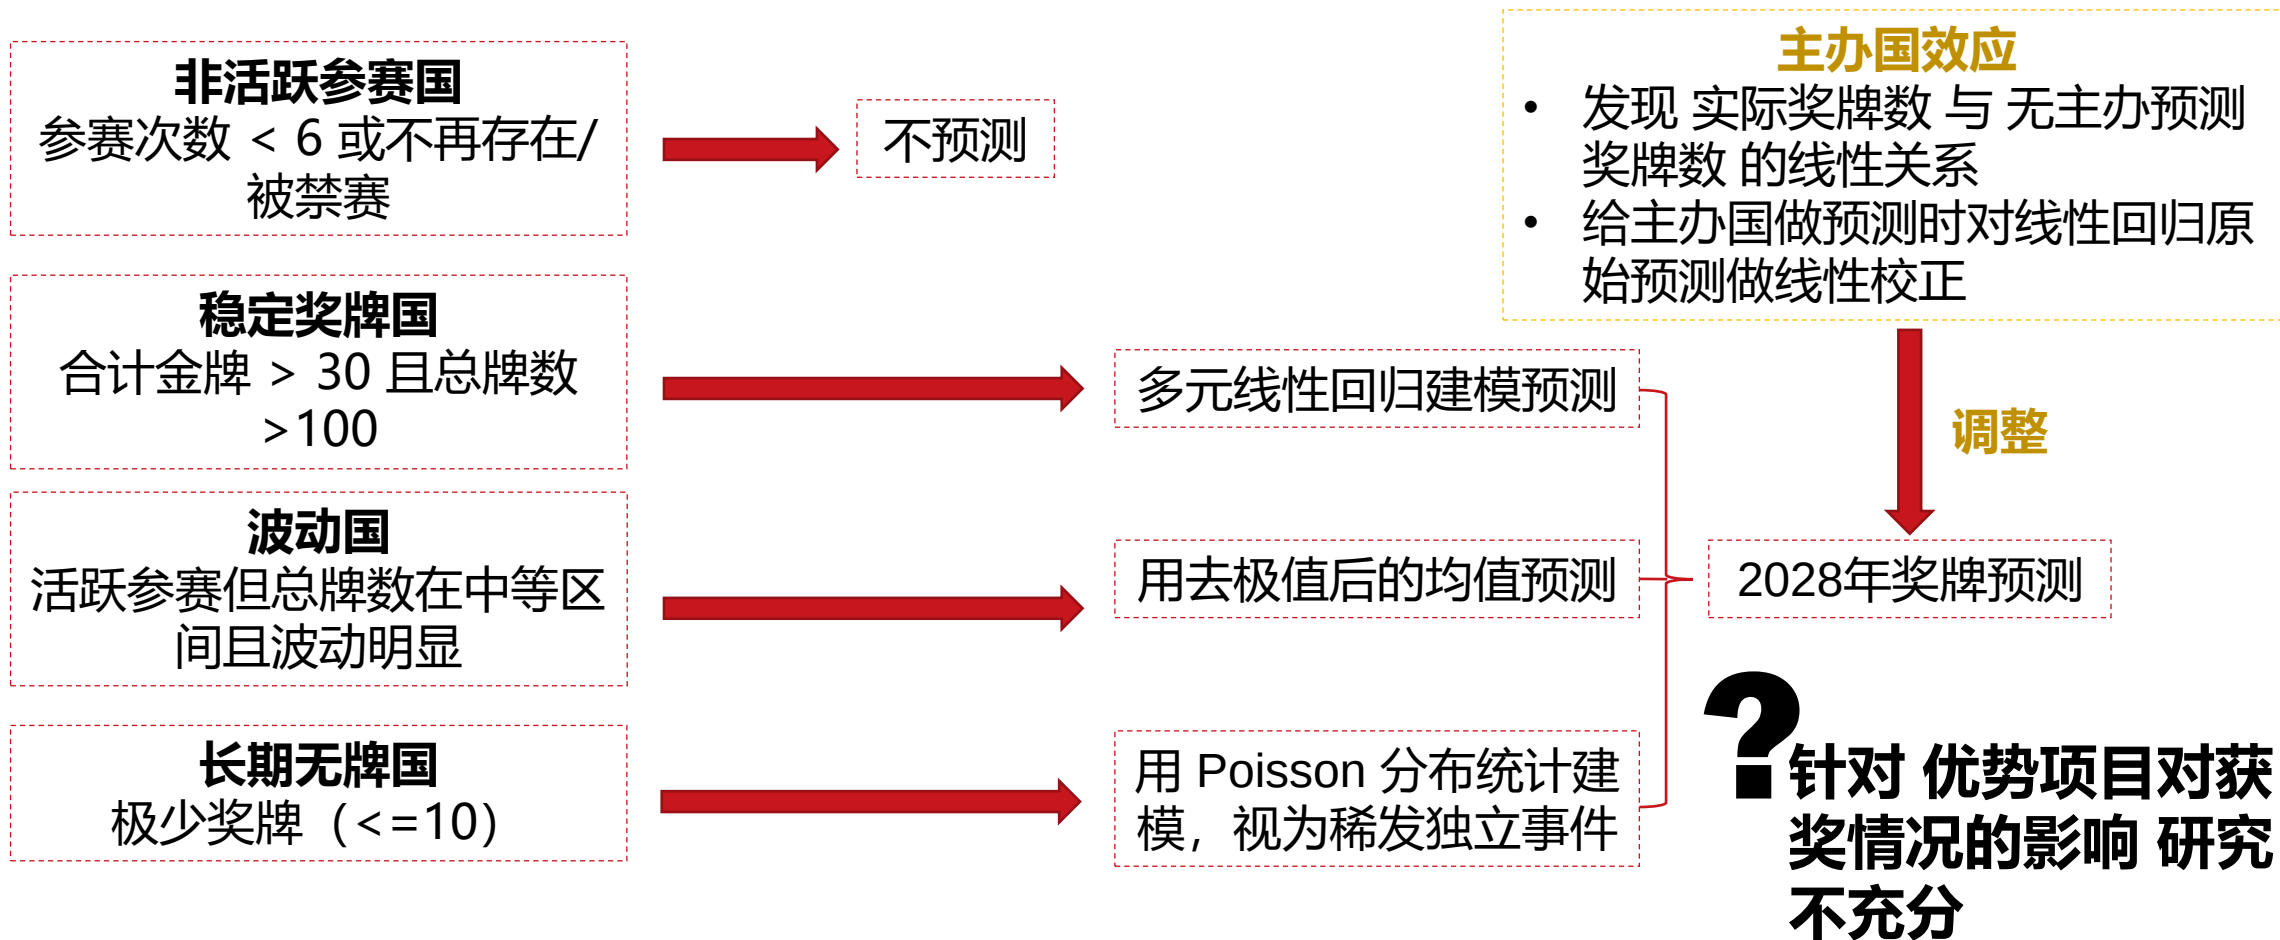
评估方法	核心作用	关键好处
TSCV	按时间顺序验证模型	防止数据泄露，确保预测结果可靠
Bootstrap	为预测值生成置信区间	量化预测不确定性，支持风险决策
MAE	衡量预测的平均误差大小	直观评估精度，便于模型对比
Poisson Error	评估计数数据的预测偏差	专为奖牌数设计，验证分布拟合优度

Highlight 3 – 可读性强



任务一：构建奖牌预测模型

不同国家奖牌数据形态差别很大，单一模型不好拟合所有情况 → 先分类再对每类用不同策略。



任务二：探究“伟大教练”的影响

Fisher精确检验
验证存在“伟大教练”效应



量化效应影响
计算“Medal Rate”与
“Gold Rate”随时间的变
化并作线性拟合



具体案例分析
对加拿大、德国、意大利特定项目进行“假设性”
投资情景预测

- 考察个体获牌率（获牌运动员数 / 参赛运动员总数）和金牌占比（金牌数 / 总牌数）
- 把“教练上任前 vs 上任后”对应的“获（金）牌 vs 未（金）获牌”放入 Fisher's Exact Test，检查是否存在独立性

亮点

模型分类思路很好，具有可解释性与实用性

- consistent medalists → 线性回归
- inconsistent medalists → 去 Extremes 均值
- non-medalists → Poisson
- inactive → 不预测


按**统计行为**特征分类，再分别建模
合理、实用、现实可解释性强



亮点

语言规范、结构清晰、图表丰富

- 图表完善
- 流程图、算法伪代码清晰
- 对建模要素、统计工具使用原因解释清晰且充分
- 引用、摘要、讨论部分完整



Algorithm 1: Olympic Medal Prediction Model

```
Input: Dataset  $D$  containing historical participation and award records in the past 3 decades
Output: Predicted total medal count and gold medal count for each country

1 for each country  $c_i \in D$  do
2   if country  $c_i$  has participated in Olympic Games less than 6 times since Atlanta 1996,
   like Lebanon or country  $c_i$  no longer exists, like the Soviet Union or country  $c_i$  has
   been prohibited from participating in recent years, like Russia then
3     Classify  $c_i$  as Inactive participants;
4     No prediction will be made;
5   else
6     if country  $c_i$  has won more than 30 gold medals and more than 100 total medals
       since 1996 then
7       Classify  $c_i$  as Consistent medalists;
8       Use a multivariate linear regression model for prediction;
9     else
10      if country  $c_i$  has won more than 10 medals since 1996 then
11        Classify  $c_i$  as Inconsistent medalists;
12        Provide an expectation for its performance based on its history;
13      else
14        Classify  $c_i$  as Persistent non-medalists;
15        Provide a statistical prediction of the Poisson distribution based on the
        overall number of such countries and their historical performance;
16      end
17    end
18  if country  $c_i$  is the host then
19    Adapt the result according to past patterns of the host effect;
20  end
21 end
22 return Predicted number of gold medals and total medals of every country;
```

任务一：构建奖牌预测模型

第一部分：问题解构与建模思路

1

核心洞察

国家奖牌数由**宏观因素**（时间相关趋势、主办国效应、综合国力）和**微观项目优势**（某国在各项目上的“主导力”）驱动

2

建模策略

单一模型无法完美捕捉两种驱动因素，采用“**分而治之，再整合**”的策略

3

逻辑落地

设计MPM模型：**基础模型**（神经网络+贝叶斯优化）和**附加模型**（PCA）



任务一：构建奖牌预测模型

第二部分：基础模型——捕捉宏观因素

Lag feature	捕捉各国历史表现
Host country	量化“主办国效应”
Total medal count	提供整届奥运会规模信息
Changes in events	提供不同届项目调整信息

- 1
- 2
- 3
- 4
- 5

模型设计

传统统计难以同时捕捉复杂非线性和交互，用神经网络学习复杂模式

核心输入

特征工程提供高质量输入

优化超参数


贝叶斯优化自动寻找最佳超参数，避免过拟合

训练与选择

以 RMSE（以及覆盖率）为评估目标，选最优超参

输出与验证

输出预测奖牌值 f_i ，并用2024年数据回测，验证模型在近期数据上的可靠性



此模型旨在回答：“如果一切按历史规律发展，不考虑国家特长，各国应得多少奖牌？”

任务一：构建奖牌预测模型

第三部分：附加模型——量化微观项目优势


- **定义原始指标**：用运动员个人数据，提取六个指标（GMD、GMI、MD、MI、NGA、NMA）
- **降维与提炼**：用 **PCA** 将六个指标降维为两个核心价值，MH（奖牌历史）与 GA（伟大运动员），标准化后求和得该国该项目统治力指标 **DS**

此模型用于回答“该国在哪些项目上具有统治力？这种统治力有多强？”

奖牌在国家与项目
内的相对重要性

“伟大运动员”数量

金牌统治力	GMD
金牌重要性	GMI
奖牌统治力	MD
奖牌重要性	MI
金牌获奖运动员人数	NGA
奖牌获奖运动员人数	NMA





F奖 - MPM: Medal Prediction Model Based on Neural Network

任务一：构建奖牌预测模型

第四部分：模型集成与最终预测

用**遗传算法**，微调融合基础模型的输出 f_i 与附加模型的 DS 值的公式中的其他参数

核心逻辑：
最终奖牌占比预测 = 宏观规律预测 + 项目结构适应性调整，实现宏观与微观因素的融合

最终产出：


2028 年完整奖牌榜预测
含 70% 置信区间

识别进退步国家
通过比较 2024 实际值与 2028 预测区间


预测首次获奖国家
用线性回归分析“新晋国家”历史数据

列出各国关键项目
通过查询各国家 DS 值最高的项目

基础模型：神经网络



附加模型：PCA



遗传算法调参
Genetic Algorithm



$$\frac{f_{i+1}}{N_{i+1}} = \frac{f_i + \Delta F_i}{N_i} + w_1 \sum_j DS_j \eta_j + w_2 + \epsilon$$



	Country/Region	Gold Medals	Total Medals
1	America	44	114
2	China	39	85
3	France	19	58
4	Britain	19	56
5	Japan	17	42
6	Australia	17	47
7	Netherlands	12	30
8	Italy	12	36
9	Korea	11	28
10	Germany	11	30

任务二：探究“伟大教练”的影响

第一部分：证据侦查

双重差分法 (DID)：

- 对照组（无教练效应）：任务一中 MPM 模型预测值 f_i
- 实验组（可能存在教练效应）：实际奖牌数 y_i
- 奖牌双重差分值： $DDM = f_i - y_i$
- 寻找 $DDM > 0$ 的异常点，若这些异常与知名教练上任时间高度相关，则为“教练效应”提供初步证据

第二部分：效应量化

建立 DID 回归模型：

$$y_{i+1} - y_i = f_{i+1} - f_i + \beta_1 D + \beta_2 DT + \epsilon$$

- D：教练是否上任（0 或 1）
- T：上任时间
- β_1 ：量化教练上任的即时冲击
- β_2 ：量化上任期间带来的持续增值

任务二：探究“伟大教练”的影响

第三部分：战略应用 —— 从度量到决策

教练投资模型 (TOPSIS + 熵权法)

TOPSIS输入关键指标：


- DS：体育项目在国家内的重要度（若本来已强则不宜投资）
- CH：该国在该项目的参赛历史（若参赛多但成绩差，说明有潜力）
- SH：项目的奥运历史（新项目易快速提升）

熵权法计算各指标权重

案例分析

选择中国（**东方体育强国**）、法国（**西方体育强国**）、印度（**非体育强国**）三个国家计算各项目优先投资度，并提出建议

为什么值得F奖



逻辑位置	数学内容	用途	下一步依赖
任务一（基础模型）	f_i	预测趋势	任务二对照基线
任务一（附加模型）	$DS \times \eta$	项目影响	任务二教练投资指标
任务二（DID 模型）	$D + DT$	教练效应量化	为教练模型提供增益基数

全文逻辑环环相扣

- 任务一与任务二呈递进关系：用任务一的结果作为任务二的基础
- 公式之间的链式结构：顺序推理建模

模型用于推理 → 推理用于机制识别
→ 机制用于决策建议

为什么值得F奖

模型构建具创造性与融合性



基础模型

神经网络+贝叶斯优化，捕捉宏观因素影响



附加模型

PCA提炼“优势得分(DS)”，量化微观优势项目影响

$$\frac{f}{dx}$$

最终集成

遗传算法巧妙融合两模型输出，展示对模型协同设计的能力


为什么值得F奖

创新性：跳出框架思考

- 量化“伟大教练”效应：跨学科使用 **DID 模型** 评估软性因素影响
- 教练投资模型：结合 TOPSIS 和熵权法，为国家提出可执行建议，形成“分析-预测-决策”闭环

可视化与可读性优秀：

- 清晰的工作流程图及核心机制示意图
- 多种形式的结果展示图





O奖 - Olympic Multi-dimensional Prediction Integrator


□ 论文架构

- 1. Introduction
- 2. Preparation for Modeling
- 3. Problems
 - a. Problem1: Medal Prediction
 - b. Problem2: The “Great Coach” Effect
 - c. Problem3: New Insights
- 4. Sensitivity Analysis
- 5. Model Analysis
- 6. Memorandum

Contents		
1	Introduction	3
1.1	Problem Background	3
1.2	Clarifications and Restatements	3
1.3	Our Work	3
2	Preparation for Modeling	3
2.1	Model Assumptions	3
2.2	Notations	4
2.3	Data Preprocessing	4
3	Problem 1: Medal Prediction	5
3.1	Medal Ranking	5
3.1.1	PCA: Reducing Dimensions	5
3.1.2	LSTM: Trends Based on Time	6
3.1.3	XGBoost-Bootstrap Modeling	9
3.1.4	Results Display	9
3.2	Breaking the Zero	10
3.3	Olympic Events and Medal Counts	13
3.3.1	Spearman: A Mathematical Analysis	13
3.3.2	SHAP: Revealing Correlations and Importance	14
3.3.3	Analysis of Relationships and Importance	15
4	Problem 2: The "Great Coach" Effect	18
4.1	DID Modeling	18
4.2	Hypothesis Testing and Contribution Coefficient Analysis	19
5	Problem 3: New Insights	19
6	Sensitivity Analysis	21
6.1	The Number of Principal Components	21
6.2	Prediction Model Evaluation	21
7	Model Analysis	22
7.1	Strength	22
7.2	Weakness and Further Discussion	23
8	Memorandum	24
	Reference	25

Highlight 1 – 整体框架清晰，逻辑性强

背景 → 任务拆解 → 数据处理 → 多模型融合预测 → 统计检验 → 敏感性分析 → 决策建议 → 备忘录



- 预测金牌/奖牌数
- 预测零突破(Zero Breakthrough)
- 分析项目的影响
- 教练变更因果分析
- 深入洞察/建议

Figure 1: The Flow Chart of Our Work

Highlight 2 – 多模型融合

“多源信息融合+时间序列+集成学习”的综合预测框架

PCA + LSTM + XGBoost + Bootstrap


模块	亮点	作用
PCA	降维 + 去噪	解决多事件特征的高维困境，提高后续模型效率
LSTM（双通道）	深度学习时间序列	能捕捉国家 medal 趋势、主场效应、准备周期等关键动态
XGBoost	非线性集成学习	模型稳定、性能强，用于最终预测
Bootstrap	非参数置信区间	给出预测的不确定性，是真正的“统计意义上的预测”

Highlight 3 – XGBoost

现代机器学习模型的运用

与上世纪就已经提出并广泛运用的PCA、Bootstrap等模型不同，XGBoost是近年来性能最强、运用最广泛的机器学习模型之一

运用XGBoost、SHAP等新模型除了可以提升自身模型的鲁棒性，还能展现团队具备最新技术能力，而不是停留在教材层面




A visualization of boosting

Highlight 4 – 解释性极强

SHAP (Shapley Additive exPlanations) 是一种用于解释机器学习模型输出的方法，将一个模型的预测结果分解成“各个特征分别贡献了多少”，并给出可量化、可对比的贡献值

论文中利用**SHAP**的**全局重要性图**、**依赖性图**和**局部力图**，全面展示了体育项目对 medal 的影响路径，使模型的解释性、透明性和可信度得到显著提升





Highlight 5 – 写作质量高

Table 1: The List of Notation



Symbol	Definition
α_c	Each country's home advantage coefficient
$\hat{p}_i$	The host advantage coefficient
β_0	Intercept, the baseline medal count for the control group
β_1	The difference between the treatment and control groups
β_2	The overall change in medal counts from 2020 to 2024
β_3	Contribution coefficient
X_{it}	Control variable matrix
γ	Coefficient of X_{it}
ϵ_{it}	Random error term
$Prep_t$	The preparatory period effect
$Threat_t$	Dummy variable indicating coach change, 1 if changed, 0 otherwise
$Post_t$	Time dummy variable, 1 if the Olympic year is 2024, 0 otherwise

Table of notations

Table 2: Predicted Medal Counts & CI for Top 20 Countries at 2028 Olympics

Gold				Total			
NOC	Gold_Pred	CI_95%	Trend	NOC	Total_Pred	CI_95%	Trend
USA	51	(32.08,58.34)	↑	USA	133	(79.60,147.35)	↑
CHN	34	(23.33,40.19)	↓	CHN	90	(59.13,103.51)	↓
AUS	19	(10.41,16.13)	↑	GBR	69	(43.12,75.84)	↓
JPN	17	(11.88,18.80)	↓	JPN	55	(38.19,64.94)	↓
GBR	16	(11.92,19.12)	↑	AUS	49	(33.37,63.77)	↑
FRA	12	(9.00,14.86)	↓	FRA	41	(29.86,60.60)	↓
GER	12	(8.41,14.38)	↓	NED	34	(24.58,39.30)	↑
ITA	11	(7.06,13.03)	↓	GER	33	(25.18,48.98)	↓
NED	11	(6.84,13.18)	↓	CAN	29	(21.72,33.68)	↓
NZL	11	(4.82,9.33)	↑	ITA	29	(22.58,34.13)	↓
CAN	10	(5.73,11.70)	↑	KOR	25	(18.08,34.28)	↓
HUN	8	(5.18,10.87)	↑	BRA	21	(14.67,24.32)	↓
KOR	7	(5.69,9.38)	↓	NZL	18	(13.98,23.86)	↓
BRA	6	(3.70,8.06)	↓	HUN	17	(13.00,22.69)	↓
ESP	5	(3.08,6.72)	↓	CUB	15	(10.91,18.57)	↑
UKR	5	(3.39,7.88)	↑	ESP	14	(8.84,19.47)	↓
KEN	5	(2.51,6.01)	↓	SWE	12	(7.06,14.99)	↓
CUB	4	(2.36,5.92)	↑	UZB	11	(8.45,13.61)	↓
UZB	4	(1.96,5.83)	↓	KEN	9	(7.63,14.35)	↓
TPE	4	(2.79,4.53)	↑	UKR	9	(6.96,11.12)	↓

Table of output



PCA Biplot




Figure 7: Violin-Raincloud Hybrid Plot




Figure 16: Scree Plot for Principal Component Selection




Figure 8: Spearman Correlation Coefficient Heatmap

Visualizations of output

O奖 - Sketch an Olympic Vision

□ 论文架构

1. Introduction
2. Assumptions and Justification
3. Models
 - a. Model1:Event Prediction
 - b. Model2:Medal Prediction
 - c. Model3:First-time Medalist Prediction
 - d. Model4:Great Coach Effect
4. Insights
5. Sensitivity Analysis
6. Strength and Weakness

Contents	
1 Introduction	3
1.1 Background	3
1.2 Literature Review	3
1.3 Problem Restatement	3
1.4 Our Work	4
2 Assumptions and Justification	5
3 Notations	5
4 Model I : Event Prediction based on SVR	6
4.1 Model Overview	6
4.2 Model Establishment	6
4.3 Results	7
4.4 Analysis of the importance of different sports	8
5 Model II : Medal Prediction based on LSTM and XGBoost	9
5.1 Model Overview	9
5.2 Data Preparation	9
5.3 Baseline: LSTM model	10
5.3.1 Model Overview	10
5.3.2 Training Process	10
5.3.3 Results	10
5.4 Advanced: XGBoost model	11
5.4.1 Model Establishment	11
5.5 Examining the confidence of the prediction interval	12
5.6 A Mann-Kendall-based analysis to project significant change in medal acquisition	13
6 Model III: First-time Medalist Prediction based on Cox Proportional Hazard Model	15
6.1 Model Overview	15
6.2 Theoretical Basis	15
6.3 Key Predictors of First-time Medalists	16
6.4 Model establishment	16
6.5 Model Fitting and Prediction	16
6.6 Monte Carlo Simulation	17
7 Model IV: Great Coach Effect	17
7.1 Model Overview	17
7.2 Effect Evidence	18
7.2.1 Threshold Method	18
7.2.2 Isolation Forest	19
7.3 GCE contribution to medal counts	19
7.4 GCE influence on certain sports	19
7.5 Application and Estimation	20
7.5.1 choosing countries and sports	20
7.5.2 Great Coach Effect Prediction	20
7.5.3 Results	21
8 Insights	22
8.1 From Models Above	22
8.2 Extra Study: Impact of Gender Ratio	23
9 Sensitivity Analysis	23
10 Strength and Weakness	24
10.1 Strength	24
10.2 Weakness	25
10.3 Room for Improvement	25
Reference	25
Appendices	1


模型一：基于SVR的项目数量预测

模型概述

建模目标：



- 预测2028年奥运会各竞赛大项的项目数量
- 评估不同运动对各国的重要性

采用方法：支持向量回归模型(SVR)




SVR

- 支持向量回归 (SVR) 是支持向量机 (SVM) 在回归问题中的拓展形式，其目标是找到一个函数，在满足特定约束条件的同时最小化目标变量的预测误差，擅长捕捉非线性模式。
- 采用核函数将输入数据映射到高维特征空间，从而使映射后的数据能够拟合线性回归模型。



模型二：基于LSTM和XGBoost的奖杯预测



模型概述

基线模型：LSTM模型

主力模型：基于XGBoost 算法的模型

模型二：基于LSTM和XGBoost的奖杯预测



数据准备

- 将数据集中的每个比赛项目归类到其对应的**大项**之下
- 统计每个国家在每个大项中获得的金、银、铜牌数量
- 将上述奖牌数量转换为**百分比**



模型训练 (LSTM基线模型)

- 输入：2024年以前的历史数据
- 输出：拟合2024年的奖牌数
- 优化器：Adam
- 学习率调度：OneCycle策略



结果评估





- 损失降至 0.0058，表明模型已良好收敛
- 但在测试集上表现不佳，存在严重过拟合现象

模型二：基于LSTM和XGBoost的奖杯预测


- 置信区间计算：计算模型预测值与实际值之间残差的标准差；假设残差服从正态分布，估算预测区间。
- 趋势分析：Mann-Kendall 检验（用于识别时间序列数据趋势的非参数方法）。

$$S = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}(x_j - x_i) \longrightarrow Z = (S - E(S))/\sqrt{Var(S)} \longrightarrow \text{p值检验}$$

Mann-Kendall 检验



模型三：基于Cox比例风险模型的首次获奖者预测



模型概述

建模目标：预测一个国家赢得其首枚奥运奖牌的概率

采用方法：Cox比例风险模型

模型三：基于Cox比例风险模型的首次获奖者预测

$$P(t, \mathbf{X}) = P_0(t) \exp(\beta_a X_a(t) + \beta_p X_p(t) + \beta_e X_e(t))$$

$P(t, \mathbf{X})$: 在年份 t 赢得首枚奖牌的概率

$P_0(t)$: 基准风险函数

$\beta_a, \beta_p, \beta_e$: 模型系数 (影响权重)



$X_a(t)$: 截至年份 t 的累计独特运动员数量

$X_p(t)$: 截至年份 t 的奥运参赛次数

$X_e(t)$: 截至年份 t 的累计参与独特项目数量

将一个国家实现奖牌“零的突破”的时刻，类比为临床医学中研究的风险事件发生。只使用了每个国家在首次赢得奖牌之前（含获奖当年）的数据，排除那些已经获得过奖牌的国家在后续年份的数；选取三个时变协变量用于风险估计；基准风险函数是非参数的，意味着其完全由数据驱动，不做任何先验假设，因此非常灵活。

模型四：伟大教练效应



模型概述

建模目标： 量化教练对一个国家奥运表现的影响

采用方法：

开发评分系统： 建立一个系统来评估奥运表现。

识别关键时间点：


结合使用阈值法和隔离森林，来识别因引入教练而导致成绩出现显著提升的时间点。

差异点

- 当一个数据点的 ΔS 或 γ_S 的值超过了其对应的阈值时，就被认为存在统计上显著的性能提升，即差异点。
- 减少方差：最小化因个别运动员的异常出色表现而导致的国家总分波动。
- 考虑小国进步：确保能够捕捉到体量较小但取得显著进步的国家。

$$\Delta S = S_i - S_{i-1}$$
$$\gamma_S = \frac{S_i}{S_{i-1}}$$

模型四：伟大教练效应



数据点的异常分数由其在不同隔离树中平均路径长度决定：

$$\text{score}(x) = -2 \frac{E(h(x))}{c}$$

隔离森林

- 隔离森林是一种基于集成的异常检测方法。该方法通过随机选择特征与特征值构建多棵隔离树来识别异常点，每棵隔离树通过随机选择特征和分割点对数据点进行隔离。
- 将一个国家历年来的差异值作为输入数据。其中数值最大的点在隔离树中路径会非常短，从而被识别为异常点。

模型四：伟大教练效应

First

量化伟大教练效应

- 对奖牌数的贡献：

$$C_i = \frac{\sum_{j \in \text{sports}} \alpha_{ij} \Delta S_{ij}}{\sum_{j \in \text{sports}} S_{ij}}$$

- 对特定项目的贡献：

$$I_s = \frac{\sum_{k \in \text{years}} \sum_{\text{countries}} \Delta S_{sk} > S_T \alpha_{sk} \Delta S_{sk}}{\sum_{k \in \text{years}} \sum_{\text{countries}} \Delta S_{sk} > S_T S_{sk}}$$

Second

选择国家和运动项目

- 教练影响力因子排名
- 历史表现处于有希望区间

Third


构建模型

- 结合回归分析和随机森林拟合函数：

$$F(S_{i-1}) = S_i$$

Fourth

案例分析&可视化



04

总结与建议



论文梳理

	主要方法	完成情况
S奖	负二项回归、几何分布、弹性网络	完成度达标：模型选择较合理，完整回答了问题。
H奖	XGBoost + SVM + CUSUM + DID	稳健可靠：精准运用成熟模型，方法论扎实，结果稳健可信。
M奖	神经网络 + PCA + 遗传算法 + DID + EWM-TOPSIS	方法多样性：主模型新颖，融合多种算法。
F奖	多目标XGBoost + SVM + CUSUM + DID + SHAP	系统性与实用性：特征工程系统，从检测到决策的完整链条。
O奖	PCA + LSTM + XGBoost + SHAP + DID	模型深度与严谨性：多层融合框架，兼具时序预测、可解释性与因果推断。
O奖(SJTU)	SVR + XGBoost + LSTM + Cox + Isolation Forest + 阈值法	方法创新广度：为各子问题定制新颖模型，覆盖全面，分析深入。

合理的模型选择

注重逻辑递进与交叉验证

- 从简单模型入手，再加入复杂模型，最后构建创新模型。
- 采用模型组合，增强结果的稳定性与可信度。


任务驱动模型构建

- 所有模型均根据不同预测任务的数学结构与数据特征专门选取，不使用多余的复杂算法。
- 在需要解释处使用高可解释模型，在需要预测处采用强预测模型。


美观的可视化

	核心目的	典型图表	在论文中的关键作用
趋势演化可视化	展示数据随时间的变化规律与未来走向	时序折线图、趋势拟合线、预测区间图	揭示规律，预测未来
模型解释性可视化	打开"黑箱"，解释模型如何做出决策	SHAP图、特征重要性图、残差图	解读黑箱，建立信任
分布与构成可视化	揭示数据的内部结构、比例与分布形态	饼图/玫瑰图、小提琴图、箱线图	诊断结构，评估稳健
关联关系可视化	探索多个变量之间的相关性与互动模式	热力图、散点图、雷达图	发现模式，定位关键
流程与机制可视化	阐明复杂的建模流程、算法步骤或因果机制	流程图、技术路线图	阐明逻辑，确保复现

清晰的逻辑展示



O奖思维导图 - 简洁、清晰且美观



S奖思维导图 - 繁杂，难以辨认

思维导图

- 思维导图是一种展示论文思路、解法过程的直观图形表达。
- 清晰、简洁的思维导图有助于读者快速理解论文内容。

简洁的公式及参数呈现

$$Var(S) = \frac{n(n-1)(2n+5) - \sum_{i=1}^m t_i(t_i-1)(2t_i+5)}{18}$$

The training process used the **Adam** optimizer with the following parameters: learning rate $lr_{\text{initial}} = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, and $\epsilon = 1 \times 10^{-8}$. The **One Cycle Learning Rate**

〇奖

$$p(X=m) = \sum p_{i_1} p_{i_2} \cdots p_{i_k} (1 - p_{i_{k+1}}) (1 - p_{i_{k+2}}) \cdots (1 - p_{i_n})$$

$$y_1 = -2.4160 - 2.0487X_3 + 4.3998X_1 + 0.7630X_1X_3 + 1.9346X_2 - 2.0267X_3^2 + 0.7717X_4X_3 + 0.7675X_4 + 1.4702X_3 + 6.0736X_1^2 + 3.6399X_1X_4 - 2.9244X_1 + 3.6366X_4^2 - 0.6745X_2X_4 + 2.2587X_2^2$$

S奖

公式及参数

- 公式尽量简洁明了、一目了然
- 清晰地展示求解出的参数



感谢聆听

THANK YOU

